Projet de Machine Learning

Fabrice Rossi

L'objectif de ce projet d'apprentissage automatique (*machine learning*) est de développer un modèle prédictif à partir d'un jeu de données réaliste. La construction du modèle s'effectuera de préférence en Python (avec des bibliothèques telles que Scikit-learn et Optuna) ou en R (avec les packages mlr3 ou tidymodels).

1 Fichiers de données

Ce projet consiste à construire un modèle prédictif afin d'estimer une caractéristique non divulguée, liée au statut socio-économique de 100091 individus résidant en France métropolitaine. La variable `target`, cible de cette prédiction, n'est disponible que dans le jeu d'apprentissage.

1.1 Structure des données

- Les données sont réparties sur plusieurs fichiers CSV, divisés en jeux d'apprentissage et de test (comprenant respectivement 50046 et 50045 individus).
- **Jeux de données principaux :** `learn_dataset.csv` et `test_dataset.csv` contiennent les informations essentielles sur les individus, incluant la variable `target` dans le jeu d'apprentissage.
- **Jeux de données liés à l'emploi :**
  - Le type d'emploi de l'ensemble des individus actifs, y compris les travailleurs non salariés tels que les indépendants, est indiqué dans `learn_dataset_EMP_CONTRACT.csv` et `test_dataset_EMP_CONTRACT.csv`.
  - `learn_datataset_job.csv` et `test_datataset_job.csv` décrivent de manière détaillée les emplois des individus bénéficiant d'un statut de salarié.
- **Jeux de données liés à la retraite :**
  - `learn_dataset_retired_former.csv` et `test_dataset_retired_former.csv` fournissent des informations sur les dernières conditions de travail des retraités (y compris les non-salariés).
  - `learn_dataset_retired_jobs.csv` et `test_dataset_retired_jobs.csv` décrivent en détail les derniers emplois des retraités qui étaient autrefois salariés.
  - `learn_dataset_retired_pension.csv` et `test_dataset_retired_pension.csv` précisent le montant de la pension de chaque individu retraité.
- **Jeux de données relatifs à l'adhésion à des clubs sportifs :** les informations concernant les individus licenciés dans des clubs de sport figurent dans `learn_dataset_club.csv` et `test_dataset_club.csv`.

Des précisions sur le contenu des fichiers, notamment quant à la nature des variables, sont apportées ci-dessous.

1.2 Considérations relatives à la manipulation des données

Ce jeu de données complet présente une structure relativement complexe. Certains sous-ensembles comportent des valeurs manquantes ; le nombre d'heures de travail pour un emploi donné peut, par exemple, être inconnu. Par ailleurs, il se peut que certaines informations fassent totalement défaut pour une personne donnée. À titre d'exemple, le dernier emploi d'une personne retraitée peut parfois être complètement ignoré.

Ces mécanismes d'omission de données sont de natures radicalement différentes : si les techniques d'imputation peuvent s'avérer efficaces pour pallier l'absence d'une valeur isolée dans la description d'un individu, imputer un grand nombre de variables risque d'aboutir à des modèles erronés. Par exemple, lorsqu'une personne n'est pas retraitée, son absence du jeu de données sur l'emploi s'explique le plus souvent par le fait qu'elle n'est pas salariée. Elle peut être au chômage, travailler à son compte, etc. Dans une telle situation, considérer ses données d'emploi comme « manquantes » constituerait une erreur fondamentale.

De surcroît, les jeux de données peuvent comporter des incohérences mineures, à l'instar d'un poste indiqué comme précaire dans le jeu de données des emplois, mais comme permanent dans celui portant sur le type d'emploi. Il est par conséquent recommandé d'implémenter quelques vérifications de cohérence élémentaires afin de s'assurer de l'intégrité des données. Si des corrections s'imposent, le jeu de données principal doit être jugé plus fiable que celui relatif au type d'emploi, ce dernier primant à son tour sur le jeu de données contenant la description détaillée de l'emploi.

Le chargement des données requiert une attention particulière. En effet, certains logiciels risquent d'interpréter le code commune INSEE (`INSEE_CODE`) comme un entier, supprimant ainsi le zéro initial de certains codes (transformant, par exemple, 01001 en 1001). Une telle altération fausserait le modèle.

1.3 Personnes

Les individus sont décrits par les variables suivantes :
— `Pkey` : clé primaire (identifiant unique) ;
— `Age_2020` : âge ;
— `Sex` : sexe ;
— `HOUSEHOLD` : type de famille ;
— `highest_credential` : diplôme le plus élevé ;
— `Act` : type d'activité ;
— `IS_STUDENT` : vrai si la personne est étudiante ;
— `Job_42` : catégorie socioprofessionnelle (norme PCS 2003, voir ci-après) ;
— `INSEE_CODE` : code INSEE de la commune de résidence.

1.4 Emploi

Les emplois actuels des personnes salariées sont décrits par les variables suivantes :
— `Pkey` : clé étrangère liée à la table des personnes ;
— `Eco_sect` : secteur économique de l'emploi ;
— `type_of_contract` : type de contrat de travail ;
— `labor_force_status` : nature de l'emploi (emploi régulier, stage, etc.) ;
— `Job_condition` : modalités de travail (temps plein, temps partiel, etc.) ;
— `working_hours` : temps de travail annuel total (cette variable comporte des valeurs manquantes) ;
— `COMPANY_CATEGORY` : type d'employeur ;

— `Employee_count` : taille de l'entreprise ;
— `Job_dep` : département où s'exerce l'emploi ;
— `Job_description` : description de l'emploi selon la nomenclature PCS-ESE 2017 (voir ci-après) ;
— `PAY` : salaire annuel de la personne.

Le dernier emploi d'une personne retraitée est décrit avec des variables quasi identiques :
— le salaire (`PAY`) n'est pas renseigné ;
— une variable supplémentaire `former_dep` indique le département de résidence de la personne retraitée à l'époque où elle occupait ce dernier emploi.

1.5 Type d'emploi

Le type d'emploi de l'ensemble des personnes pourvues d'un travail est indiqué par la variable `EMP_CONTRACT` dans le fichier CSV correspondant. Le lien avec le fichier des personnes s'effectue via la clé étrangère `Pkey`. Les personnes ayant un emploi ne disposent pas systématiquement d'un statut de salarié ; il est donc tout à fait normal de rencontrer des individus associés à un type d'emploi sans qu'aucune description détaillée de ce dernier ne soit fournie.

1.6 Ancien type d'emploi

L'ancien type d'emploi des personnes retraitées est décrit par les variables suivantes dans les fichiers `learn_dataset_retired_former.csv` et `test_dataset_retired_former.csv` :
— `Pkey` : clé étrangère liée à la table des personnes ;
— `FORMER_EMP_CONTRACT` : le type d'emploi (identique aux personnes actives) ;
— `Former_job_42` : catégorie socioprofessionnelle (norme PCS 2003, voir ci-après) ;
— `retirement_age` : l'âge de départ à la retraite de la personne.

1.7 Sport

Lorsqu'une personne est licenciée dans un club de sport, le club concerné est décrit par une variable `club` dans le fichier CSV associé. Le lien avec le fichier des personnes est assuré par la clé étrangère `Pkey`. Ce jeu de données est présumé exhaustif : si une personne n'y figure pas, cela signifie qu'elle n'est membre d'aucun club de sport.

1.8 Variables catégorielles et géographie

La grande majorité des variables sont de nature catégorielle. Les valeurs possibles sont listées et documentées dans des fichiers CSV reprenant le nom de ces variables (par exemple `code_highest_credential.csv` pour la variable `highest_credential`).

La nomenclature PCS-ESE 2017 de l'INSEE est détaillée dans les fichiers suivants :
— `code_Job_description.csv` fait correspondre les codes aux professions ;
— `code_Job_description_map.csv` établit une correspondance entre les codes complets (N3) utilisés dans le jeu de données et deux niveaux de représentation plus agrégés (N1 et N2) ;
— `code_Job_description_n2.csv` associe les codes aux groupes de professions au niveau N2 ;
— `code_Job_description_n1.csv` associe les codes aux groupes de professions au niveau N1.

La PCS 2003 est une nomenclature complémentaire qui vient enrichir les modalités du niveau N2 de la PCS-ESE 2017. Les codes correspondants figurent dans `code_Job_42.csv`.

Les informations géographiques et administratives relatives aux communes de France métropolitaine sont réparties dans plusieurs fichiers :

- `city_adm.csv` regroupe les informations administratives :
  - `Nom de la commune` : le nom de la ville ;
  - `INSEE_CODE` : le code INSEE de la commune ;
  - `dep` : le code du département de la commune ;
  - `city_type` : le type de commune (les modalités correspondent aux statuts administratifs des communes) ;
- `city_loc.csv` rassemble les informations géographiques, notamment les coordonnées GPS des communes dans le système WGS 84 ainsi que dans la projection Lambert-93. Ces coordonnées Lambert-93 permettent d'estimer les distances (en mètres) entre les communes de France métropolitaine avec une précision très satisfaisante.
  - Attributs :
  - `INSEE_CODE` : le code INSEE de la commune ;
  - `LAT` : la latitude ;
  - `long` : la longitude ;
  - `X` : la coordonnée X Lambert ;
  - `Y` : la coordonnée Y Lambert ;
- `city_pop.csv` contient les données démographiques :
  - `INSEE_CODE` : le code INSEE de la commune ;
  - `INHABITANTS` : la population de la commune.
- `deparments.csv` rassemble les données départementales :
  - `Nom du département` : le nom du département ;
  - `dep` : le code du département ;
  - `Reg` : le code de la région à laquelle le département est rattaché.
- `regions.csv` répertorie les informations régionales (découpage de 2018) :
  - `Nom de la région` : le nom de la région ;
  - `Reg` : le code de la région.

Les clubs de sport sont rattachés à des fédérations sportives, elles-mêmes classées selon plusieurs grandes catégories, telles que documentées dans le fichier `code_club.csv`.

Ces fichiers de documentation constituent une aide précieuse pour appréhender la structure des données. Ils peuvent par ailleurs s'avérer utiles pour l'ingénierie des caractéristiques (*feature engineering*), par exemple pour réduire le nombre de modalités des variables qui en comptent un trop grand nombre.

2 Résultats attendus

Ce projet a pour but de construire un modèle prédictif pour la variable `target` en s'appuyant sur les autres variables. Plus spécifiquement, il est attendu de votre part que vous :

- construisiez un modèle prédictif à l'aide des données d'apprentissage ;
- estimiez les performances futures de ce modèle sur des données inédites ;
- fournissiez les prédictions générées par votre modèle sur le jeu de test.

Le respect des règles suivantes est impératif :

- Le recours à des assistants d'intelligence artificielle est autorisé pour vous aider dans l'écriture du code, y compris pour des besoins de visualisation (par exemple, pour vous éviter de perdre du temps à déchiffrer la « documentation » de matplotlib). Toutefois, il est formellement interdit d'utiliser une IA pour rédiger une quelconque partie du rapport.

N'essayez pas non plus d'enjoliver votre document avec des images générées par l'IA.

— L'emploi d'une technique de rééchantillonnage pour sélectionner le meilleur modèle est obligatoire (il peut s'agir, par exemple, d'une validation croisée à v blocs pour les modèles génériques, ou d'une estimation *leave-one-out* ou *out-of-bag* pour des modèles spécifiques). Le jeu de données étant relativement volumineux, une simple approche par échantillon divisé (*split sample*) peut constituer la seule alternative viable sur des machines limitées en ressources.
— Les hyperparamètres principaux des algorithmes d'apprentissage automatique devront être sélectionnés via une méthode de rééchantillonnage.
— Les observations présentant des données manquantes ne devront sous aucun prétexte être retirées du jeu de test.

Par ailleurs, les recommandations suivantes pourraient vous être bénéfiques :

— Au vu de sa taille conséquente, il est judicieux de déboguer votre programme sur un sous-échantillon du jeu d'apprentissage.
— Il convient d'enrichir le jeu de données central (à savoir, la description générale des individus) avec les informations issues des autres fichiers (emplois, sports, géographie, etc.). En pratique, l'utilisation exclusive du jeu de données principal a très peu de chances d'aboutir à des performances prédictives satisfaisantes.
— Les forêts aléatoires devront servir d'algorithme de référence. Évaluer l'algorithme des K plus proches voisins s'apparenterait très probablement à un gaspillage de ressources de calcul. Les modèles linéaires peuvent certes offrir des performances acceptables, mais exigent de la prudence au regard de la nature des données (forte corrélation potentielle entre les variables, nombre pléthorique de modalités, etc.). Par ailleurs, tester de simples arbres de décision n'a que peu d'intérêt, dans la mesure où ils constituent des cas particuliers du boosting. Ce dernier, s'il est correctement ajusté, devrait d'ailleurs vous livrer les meilleures performances.
— Il est conseillé de procéder à une simplification ou à un regroupement des modalités pour les variables catégorielles qui en comptent un trop grand nombre (plus d'une centaine, par exemple). À titre d'illustration, l'utilisation brute de la variable `Job_description` posera assurément des difficultés à certains modèles prédictifs. Il est tout à fait permis de s'appuyer sur des données externes pour simplifier ces catégories.
— Vous êtes autorisés à exploiter des données externes (c'est-à-dire non incluses dans l'archive fournie) pour étoffer vos variables.
— Gardez à l'esprit qu'un « modèle » ne se résume pas à une simple forêt aléatoire. D'une part, il se doit d'englober l'ensemble des étapes de prétraitement ; d'autre part, la complexité structurelle des données peut tout à fait justifier que le modèle final prenne la forme d'une combinaison de plusieurs sous-modèles appliqués sous condition. Vous pourriez, par exemple, concevoir un modèle dédié aux individus disposant d'une description précise de leur emploi, et un autre pour ceux dépourvus de ces informations.

3 Soumission du projet

Les livrables du projet devront être déposés sur Moodle sous la forme d'une unique archive ZIP contenant :

— un rapport détaillant l'analyse prédictive (exclusivement au format PDF ; tout autre format sera rejeté). Ce document devra être concis et aller droit à l'essentiel. Il exposera la méthodologie suivie pour construire le modèle retenu. Évitez d'y inclure des éléments

s'apparentant à des notes de cours (je connais déjà la définition de la validation croisée à v blocs, il est inutile de me la rappeler). Plus précisément, ce rapport devra apporter des réponses claires aux questions suivantes :

- Quelles données externes ont été exploitées en complément de celles fournies pour le projet ?
- Quelles données ont servi à l'entraînement des modèles ? (Cette réponse peut varier selon le modèle.)
- Quels traitements préalables ont été opérés ? (Ceci peut également dépendre du modèle.)
- Quels modèles ont été expérimentés, et quelle grille d'hyperparamètres a été employée pour affiner chacun d'eux ? (Des méthodes d'optimisation plus avancées peuvent bien entendu se substituer à une recherche sur grille.)
- Quelle stratégie de rééchantillonnage a permis de sélectionner les hyperparamètres ainsi que le modèle final ?

Ce rapport devra obligatoirement inclure une estimation explicite de la qualité des prédictions attendue sur de nouvelles données, exprimée sous une forme adaptée (par exemple, le coefficient de détermination R^2 et l'erreur quadratique moyenne pour les problèmes de régression). Je m'attends à y lire une formulation du type : « Les performances attendues de notre modèle final sur de nouvelles données sont de l'ordre de xxx. »

Le rapport fournira par ailleurs une évaluation exhaustive des prédictions du modèle, appuyée par des tableaux et des visualisations appropriés. En classification, par exemple, on s'attendra à y trouver une matrice de confusion, ainsi qu'une évaluation fondée sur des scores (telle qu'une courbe ROC, si applicable). Des analyses complémentaires pourront porter sur l'importance des variables, l'investigation des erreurs de prédiction majeures, etc.

- un fichier intitulé `predictions.csv` contenant les valeurs prédites de `target` sur le jeu de test, respectant scrupuleusement la convention suivante :
  - le fichier comportera deux colonnes, dans cet ordre :
    1. `Pkey` : la clé étrangère reliant la prédiction à l'individu du jeu de test ;
    2. `target` : la prédiction en elle-même.
  - le fichier devra être au format CSV, en utilisant la virgule comme séparateur ;
  - les nombres décimaux adopteront impérativement la notation standard américaine (par exemple, 2.5).
- l'intégralité du code source ayant servi à l'analyse. Je dois être en mesure d'exécuter ce code sans y apporter la moindre modification, simplement en décompressant votre archive et en plaçant les données fournies dans le même répertoire que le code (ou dans un sous-répertoire que vous aurez préalablement spécifié dans le rapport). Vous êtes libres d'inclure les données d'origine dans votre dépôt, et vous êtes tenus d'y joindre toute éventuelle donnée externe utilisée.

Sachez qu'aucune altération manuelle des fichiers de données (via Excel, par exemple) n'est tolérée. En particulier, si des fichiers de données doivent être fusionnés, cette opération devra impérativement être codée en R ou en Python. Il est par ailleurs vivement conseillé de rédiger le rapport dans une démarche reproductible, en utilisant R Markdown, Quarto ou Jupyter Book. Notez bien que les exports PDF ou HTML natifs de Jupyter Notebook sont visuellement médiocres et ne satisfont en aucun cas aux exigences minimales de présentation de ce projet.

Enfin, la qualité des prédictions pèsera pour beaucoup dans l'évaluation du projet. Celle-ci sera calculée de façon automatisée à partir de votre fichier `predictions.csv`. Si ce fichier est mal nommé, s'il déroge au format stipulé plus haut, ou si certaines prédictions viennent à manquer,

cette partie du projet sera d'office considérée comme non validée.