

Projet : clustering des données Santander Cycles à Londres

1 Contexte et objectif

On considère les données publiques du service de vélos partagés Santander Cycles à Londres. Les données des trajets sont disponibles sur le portail Transport for London :

<https://cycling.data.tfl.gov.uk/#!usage-stats%2F>

Chaque fichier contient des informations sur les trajets réalisés : station de départ, station d'arrivée, date et heure de début et de fin, durée du trajet, etc. Dans ce projet, on s'intéressera uniquement aux trajets réalisés pendant l'année 2025.

L'objectif du projet est d'analyser le réseau Santander Cycles selon deux points de vue complémentaires : une représentation vectorielle des stations et une représentation par graphe des flux entre stations.

On cherchera en particulier à appliquer les méthodes vues en cours (clustering, réduction de dimension et détection d'anomalies) pour répondre à la question suivante :

Dans quelle mesure les différentes représentations des données permettent-elles de comprendre la structure et l'évolution du réseau Santander Cycles à Londres ?

2 Préparation et description des données

2.1 Construction de la base de travail

Télécharger et agréger l'ensemble des fichiers contenant les trajets réalisés en 2025. Construire un tableau de données contenant au minimum les variables suivantes :

- identifiant ou nom de la station de départ ;
- identifiant ou nom de la station d'arrivée ;
- date et heure du départ ;
- date et heure d'arrivée ;
- durée du trajet.

Optionnel : on pourrait éventuellement enrichir cette base avec les coordonnées GPS des stations à partir du flux BikePoint de Transport for London.

2.2 Nettoyage des données

Explorer les données et traiter par nettoyage les cas suivants :

- trajets avec station de départ ou d'arrivée manquante ;
- trajets de durée nulle ou négative ;
- trajets dont la station de départ est égale à la station d'arrivée ;
- incohérences éventuelles dans les noms ou identifiants de stations.

2.3 Description générale

Proposer une première analyse descriptive des données, en commentant les résultats. On pourra calculer, par exemple :

- le nombre total de trajets en 2025 ;
- le nombre ou le ratio de stations actives ;

- le nombre ou le ratio de stations utilisées comme stations de départ ;
- le nombre ou le ratio de stations utilisées comme stations d'arrivée ;
- la distribution du nombre de trajets par jour ;
- la distribution du nombre de trajets par station ;
- la distribution des durées de trajets ;
- la répartition des trajets selon le jour de la semaine ;
- la répartition des trajets selon l'heure de la journée.

3 Analyse des stations sans prendre en compte le réseau

Dans cette partie, les stations seront étudiées sans prendre en compte la structure du graphe origine-destination.

3.1 Construction de profils de stations

Pour chaque station, construire un ensemble de *features* décrivant son activité. On pourra, par exemple, calculer :

- le nombre total de trajets partant de la station ;
- le nombre total de trajets arrivant à la station ;
- le ratio entre départs et arrivées ;
- la durée moyenne des trajets partant de la station ;
- la durée moyenne des trajets arrivant à la station ;
- le nombre moyen de départs par jour ;
- le nombre moyen d'arrivées par jour ;
- la proportion de trajets effectués le matin ;
- la proportion de trajets effectués le soir ;
- la proportion de trajets effectués le week-end ;
- la variabilité journalière de l'activité ;
- la variabilité horaire de l'activité.

Construire ensuite des représentations temporelles plus fines :

- nombre de départs et d'arrivées par station et par jour ;
- nombre de départs et d'arrivées par station, par jour et par heure ;
- agrégation à l'échelle de la semaine ;
- agrégation à l'échelle du mois.

On pourra comparer plusieurs représentations d'une station : profil global, profil journalier moyen, profil horaire moyen, profil semaine/week-end, profil mensuel.

3.2 Réduction de dimension

Appliquer les méthodes de réduction de dimension vues en cours aux profils de stations. On utilisera au moins l'ACP et une méthode non linéaire. Questions à discuter éventuellement :

- Les premières composantes de l'ACP sont-elles interprétables ?
- Les stations se répartissent-elles selon un gradient clair ?
- Observe-t-on des groupes naturels de stations ?
- Les visualisations non linéaires mettent-elles en évidence une structure plus nette que l'ACP ?
- Certaines stations apparaissent-elles comme isolées ou atypiques ?

3.3 Clustering des stations

Appliquer au moins une méthode de clustering vue en cours aux profils des stations. Questions à discuter éventuellement :

- Combien de groupes de stations semblent raisonnables ?
- Peut-on interpréter les groupes de stations ?
- Les groupes correspondent-ils à des stations résidentielles, touristiques, centrales, périphériques, ... ?
- Les clusters ont-ils une cohérence spatiale lorsqu'on les représente sur une carte ?

3.4 Détection d'anomalies

À partir des profils de stations, utiliser au moins une méthode de détection d'anomalies vue en cours. On pourra, par exemple, rechercher :

- des stations avec un ratio départs/arrivées extrême ;
- des stations avec une activité très faible ou très forte ;
- des stations dont le profil horaire est atypique ;
- des stations très différentes de leur voisinage dans l'espace réduit ;
- des stations mal représentées par les clusters ;
- des stations avec une variabilité temporelle inhabituelle.

Les anomalies identifiées devront être interprétées : s'agit-il probablement d'erreurs, de stations particulières, de stations très touristiques, de stations en bordure du réseau, ou de comportements rares mais plausibles ?

4 Analyse des stations en prenant en compte le réseau

Dans cette partie, les flux entre stations seront utilisés explicitement pour construire une structure de graphe.

4.1 Construction du graphe origine-destination

À partir des données brutes, construire un graphe orienté pondéré :

$$G = (V, E),$$

où :

- les nœuds sont les stations ;
- une arête orientée $i \rightarrow j$ existe s'il y a au moins un trajet partant de la station i et arrivant à la station j ;
- le poids w_{ij} est le nombre de trajets observés de i vers j en 2025.

Décrire le graphe obtenu : nombre de nœuds, nombre d'arêtes, distribution des degrés entrants, distribution des degrés sortants, distribution des poids d'arêtes, stations les plus centrales, stations avec fort déséquilibre entre flux entrants et sortants.

Optionnel : construire éventuellement plusieurs graphes en agrégeant les flux selon différentes périodes : matin, après-midi, soir, nuit, semaine, week-end, mois, saison. Questions à traiter éventuellement :

- *Le graphe du matin ressemble-t-il au graphe du soir ?*
- *Les flux changent-ils d'orientation entre le matin et le soir ?*
- *Le graphe du week-end a-t-il la même structure que le graphe de semaine ?*
- *Certaines stations changent-elles de rôle selon la période considérée ?*
- *Les communautés du graphe sont-elles stables dans le temps ?*

4.2 Clustering du graphe par SBM

Utiliser un modèle de blocs stochastiques pour réaliser un clustering des stations à partir du graphe de flux. Questions à traiter éventuellement :

- Combien de classes faut-il retenir ?
- Les classes obtenues sont-elles équilibrées ou très hétérogènes en taille ?

- Comment interpréter les classes ?
- Les classes correspondent-elles plutôt à des rôles fonctionnels dans le réseau ?
- Observe-t-on des classes fortement émettrices, fortement réceptrices, centrales ou périphériques ?
- Les blocs du SBM mettent-ils en évidence des flux importants entre certains groupes de stations ?

4.3 Comparaison entre clustering vectoriel et clustering de graphe

Comparer les clusters obtenus sans prendre en compte le réseau avec les clusters obtenus par SBM.

- Les deux approches produisent-elles des groupes similaires ?
- Que capture le clustering vectoriel que le SBM ne capture pas, et inversement ?
- Quelle représentation semble la plus pertinente pour comprendre le fonctionnement du réseau ?

5 Attendus du rapport

Le rapport devra contenir :

- une description claire des données utilisées ;
- une justification des choix de nettoyage ;
- des visualisations pertinentes en utilisant la réduction de dimension ;
- au moins une méthode de clustering sur données vectorielles ;
- une application du modèle SBM ;
- une comparaison entre clustering vectoriel et clustering de graphe ;
- une discussion critique des résultats.

Les codes utilisés devront être fournis sous forme de notebooks ou de scripts reproductibles.

6 Extensions possibles

Les éléments suivants peuvent être traités comme des bonus :

- visualisation cartographique avancée ;
- intégration de données externes, par exemple météo, événements ou jours fériés ;
- étude de la stabilité temporelle des communautés du graphe.